


Democratizando los métodos de Deep Learning mediante herramientas de AutoML

Manuel García-Domínguez 

magarcd@unirioja.es

Dpto. de Matemáticas y Computación, Universidad de La Rioja

Palabras clave: Deep Learning, Transfer Learning, AutoML

Las técnicas de Inteligencia Artificial, y en concreto de aprendizaje profundo, o en inglés *Deep Learning* [1], se han convertido en el estado del arte para lidiar con problemas de Visión por Computador en casi cualquier ámbito. Este crecimiento se debe a la gran cantidad de imágenes que se capturan diariamente, el incremento de la capacidad de cálculo gracias al desarrollo de hardware específico, y el acceso libre a las herramientas necesarias para crear modelos de *Deep Learning*. A pesar de su éxito, los métodos de *Deep Learning* presentan una serie de problemas. Esta tecnología no es sencilla de utilizar y requiere de cierta experiencia y conocimientos técnicos. Además, no hay siempre un algoritmo, o una librería, que consiga los mejores resultados para cualquier situación [2], por lo que es necesario conocer y probar múltiples de ellos. Otro problema añadido es la necesidad de obtener un gran número de imágenes anotadas para poder construir modelos precisos [3]. Esto puede ser un reto en contextos como el biomédico donde puede ser difícil conseguir un número suficiente de imágenes, y donde el proceso de anotación es costoso y requiere de conocimiento experto. Por último, una vez que un modelo de *Deep Learning* se ha construido, este debe ser capaz de generalizar a contextos no previstos en el momento de su construcción; sin embargo, en muchas ocasiones los modelos no funcionan correctamente cuando se usan imágenes de un dominio, o estilo, diferente al que se usó originalmente para entrenar dichos modelos. Este problema se conoce como el problema del cambio de dominio [4, 5].

El objetivo de nuestro trabajo ha sido dar solución a los problemas mencionados anteriormente mediante el desarrollo de técnicas y herramientas

Este trabajo fue parcialmente apoyado por Ministerio de Economía, Industria y Competitividad [MTM2017-88804-P], Ministerio de Ciencia e Innovación [PID2020-115225RB-I00 / AEI / 10.13039/501100011033], Agencia de Desarrollo Económico de La Rioja [ADER-2017-I-IDD-00018] y una beca FPI de la comunidad de La Rioja 2018.

que sean accesibles a la mayor cantidad de usuarios posibles. En primer lugar hemos desarrollado herramientas que permiten crear de manera sencilla modelos precisos de *Deep Learning* para la clasificación y la detección de objetos en imágenes. Para ello se han empleado técnicas de AutoML [6] que buscan de forma automática el mejor modelo para un conjunto de imágenes dadas. Además, hemos desarrollado un método para aplicar aumento de datos [3, 7] a distintos problemas de Visión por Computador. Este método ha sido implementado en una herramienta que permite generar datasets de imágenes lo suficientemente grandes para alimentar a los modelos de *Deep Learning* en distintas tareas de Visión por Computador como son la clasificación, la detección de objetos o la segmentación semántica de imágenes y vídeos. Además de herramientas para facilitar la creación de modelos de *Deep Learning*, se ha desarrollado una herramienta que mediante técnicas de traducción desparejada de imágenes (en inglés, *unpaired image-to-image translation* [8]) y transferencia de estilos (en inglés, *style transfer*), permite lidiar con el problema del cambio de dominio [5, 4] en cualquier problema de Visión por Computador. Es importante notar que no solo hemos desarrollado métodos y herramientas desde un punto de vista teórico, sino que todo el conocimiento adquirido durante el desarrollo de dichas herramientas ha servido para abordar problemas biomédicos reales como son la segmentación de esferoides [9], la clasificación y segmentación de imágenes de motilidad [10], o la predicción de enfermedades de la retina a partir de imágenes del fondo del ojo [11]. Finalmente, los conocimientos obtenidos al resolver estos problemas biomédicos nos han servido para mejorar las herramientas desarrolladas.

Bibliografía

- [1] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521:436—444, 2015.
- [2] Mehryar Mohri, Afshin Rostamizadeh, and Ameet Talwalkar. *Foundations of Machine learning*. MIT press, 2012.
- [3] Patrice Simard et al. Tangent prop-a formalism for specifying selected invariances in an adaptive network. In *Neural Information Processing Systems*, volume 91, pages 895–903, 1991.
- [4] Anirudh Choudary et al. Advancing medical imaging informatics by deep learning-based domain adaptation. *Year book of medical informatics*, 29(1):129–138, 2020.
- [5] Ida Arvidsson et al. Generalization of prostate cancer classification for multiple sites using deep learning. In *IEEE 15th International Symposium on Biomedical Imaging*, pages 191–194, 2018.

- [6] Isabelle Guyon et al. AutoML challenge 2015: Design and first results. In *Proc. of AutoML 2015@ICML*, 2015.
- [7] Patrice Simard, Dave Steinkraus, and John C. Platt. Best practices for convolutional neural networks applied to visual document analysis. In *12th International Conference on Document Analysis and Recognition*, volume 2, pages 958–964, 2003.
- [8] Taesung Park et al. Contrastive learning for unpaired image-to-image translation. In *European Conference on Computer Vision*, page 319–345, 2020.
- [9] Manuel García-Domínguez et al. Neural style transfer and unpaired image-to-image translation to deal with the domain shift problem on spheroid segmentation, 2021.
- [10] Ángela Casado-García et al. Motilityj: An open-source tool for the classification and segmentation of bacteria on motility images. *Computers in Biology and Medicine*, 136:104673, 2021.
- [11] Ángela Casado-García et al. Prediction of epiretinal membrane from retinal fundus images using deep learning. pages 3–13, 2021.