

# Simplificando el uso y construcción de modelos de aprendizaje profundo para la clasificación de imágenes

Adrián Inés Armas 

adines@unirioja.es

Dpto. de Matemáticas y Computación, Universidad de La Rioja

**Palabras clave:** Deep Learning, Clasificación de imágenes, Democratización

La Inteligencia Artificial, y en concreto el Aprendizaje Profundo (en inglés *Deep Learning*), ha cobrado gran importancia en los últimos años debido al rápido aumento de la capacidad de procesamiento, a la disponibilidad de una gran cantidad de datos y al surgimiento de diferentes librerías de código abierto que permiten su uso de manera sencilla y libre [1]. Es por esto que las técnicas de *Deep Learning* se han convertido en el estado del arte para trabajar en diferentes problemas científicos y en concreto en el análisis de imágenes [2]. A menudo, los problemas de análisis de imágenes requieren realizar tareas repetitivas que consumen una gran cantidad de tiempo, y las técnicas de *Deep Learning* son capaces de resolver estas tareas repetitivas de manera más rápida y eficiente. En concreto, estas técnicas han permitido grandes avances en diferentes campos como la seguridad [3], la medicina [4] o la biología [5]. Sin embargo, el uso de las técnicas de *Deep Learning* no es trivial. Para su uso es necesario contar con una gran cantidad de recursos computacionales, por ejemplo hardware específico como GPUS o TPUS. Además, es necesario contar con una gran cantidad de datos anotados [6], algo que en campos como la medicina o la biología puede ser difícil de conseguir. Por último, es necesario contar con un conocimiento experto de estas técnicas tanto para construir modelos de *Deep Learning* como para usarlos [7]. Estas necesidades dificultan la adopción y democratización del *Deep Learning* en campos como la medicina o la biología, donde la cantidad de recursos de datos es limitada, y en general, en cualquier campo distinto a las ciencias de la computación debido a la necesidad de un conocimiento experto. Así, hemos identificado tres desafíos relacionados con el uso de las técnicas de *Deep Learning*, que son: la cantidad de datos necesaria para el

---

Subvencionado parcialmente por el Ministerio de Ciencia e Innovación [PID2020-115225RB-I00 / AEI / 10.13039/501100011033], y por la Agencia de Desarrollo Económico de La Rioja [ADER 2022-I-IDI-00015]

uso de estas técnicas, la democratización de la construcción de modelos de *Deep Learning* y la democratización del uso de modelos de *Deep Learning*.

El objetivo de este trabajo es analizar estos desafíos y crear técnicas y herramientas que ayuden a mitigarlos en el contexto de la clasificación de imágenes. En primer lugar nos hemos centrado en reducir la cantidad de datos necesarios para usar las técnicas de *Deep Learning*. Para ello, hemos desarrollado un *framework* llamado CLoDSA [8] que permite realizar aumento de datos para problemas de clasificación, detección y segmentación de imágenes. Además, hemos creado dos algoritmos de aprendizaje semi-supervisado que permiten entrenar modelos de *Deep Learning* usando datos anotados y sin anotar. El primer algoritmo está basado en la destilación de datos y modelos [9], mientras que el segundo utiliza técnicas del análisis topológico de datos [10].

Con el fin de democratizar la construcción de modelos de *Deep Learning*, hemos desarrollado una herramienta de *AutoML*, llamada ATLASS [9], que asiste al usuario en todo el proceso de creación de un modelo de clasificación de imágenes, desde la anotación de las imágenes, hasta la creación y uso de dicho modelo de *Deep Learning*. Esta herramienta ha sido validada con varios datasets obteniendo mejores resultados que otras herramientas de *AutoML*.

El problema de la democratización del uso de modelos de *Deep Learning* se ha abordado de dos maneras distintas. En primer lugar, para tratar de reducir la cantidad de recursos necesarios para el uso de estos modelos, se ha estudiado la combinación de métodos semi-supervisados con redes compactas y técnicas de cuantificación, lo que ha permitido reducir la cantidad de recursos computacionales necesarios para entrenar y usar modelos de *Deep Learning* [11]. Los modelos creados con esta aproximación tienen un rendimiento similar, o incluso superior, a los modelos de tamaño estándar y además son más rápidos y ligeros. En segundo lugar se ha abordado la democratización del uso de modelos de *Deep Learning* creando un *framework* llamado DeepClas4Bio [12], que proporciona un punto de acceso común para los modelos de clasificación de varias librerías de *Deep Learning* y facilita la interoperabilidad de las herramientas de bioimagen con modelos de *Deep Learning*. Además, se han creado una serie de *plugins* para la conexión de las principales herramientas biomédicas con dicho *framework*.

Por último, las técnicas y herramientas nombradas previamente han sido la base para abordar dos problemas biomédicos reales, como son la medición de la propagación de bacterias en imágenes de motilidad [13] y la detección de enfermedades de la membrana epirretiniana a partir de imágenes de fondo de ojo [14].

## Bibliografía

- [1] Y. LeCun, Y. Bengio, and G. Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015.
- [2] E. Meijering. A bird’s-eye view of deep learning in bioimage analysis. *Computational and Structural Biotechnology Journal*, 18(1):2312–2325, 2020.
- [3] S. Akçay, M. E. Kundegorski, M. Devereux, et al. Transfer learning using convolutional neural networks for object classification within x-ray baggage security imagery. In *2016 IEEE International Conference on Image Processing, ICIP’16*, pages 1057–1061, 2016.
- [4] T. Araújo, G. Aresta, E. Castro, et al. Classification of breast cancer histology images using convolutional neural networks. *PLoS ONE*, 12(6), 2017.
- [5] C. Affonso, A. L. Debiasso Rossi, F. H. A. Vieira, et al. Deep learning for biological image classification. *Expert Systems with Applications*, 85(1):114–122, 2017.
- [6] A. Asperti and C. Mastronardo. The effectiveness of data augmentation for detection of gastrointestinal diseases from endoscopical images. In *11th International Joint Conference on Biomedical Engineering Systems and Technologies*, volume 2 of *BIOSTEC 2019*, pages 199–205. SciTePress, 2018.
- [7] J. Irvin, P. Rajpurkar, M. Ko, et al. Chexpert: A large chest radiograph dataset with uncertainty labels and expert comparison. In *Thirty-Third AAAI Conference on Artificial Intelligence*, volume 33 of *AAAI’19*, pages 590–597, 2019.
- [8] Á. Casado, C. Domínguez, M. García-Domínguez, et al. Clodsa: a tool for augmentation in classification, localization, detection, semantic segmentation and instance segmentation tasks. *BMC Bioinformatics*, 20, 2019.
- [9] A. Inés, C. Domínguez, J. Heras, et al. Biomedical image classification made easier thanks to transfer and semi-supervised learning. *Computer Methods and Programs in Biomedicine*, 198:105782, 2021.
- [10] A. Inés, C. Domínguez, J. Heras, et al. A topological approach for semi-supervised learning, 2022.

- [11] A. Inés, A. Díaz-Pinto, C. Domínguez, et al. Analysing semi-supervised learning for image classification using compact networks in the biomedical context. *Soft Computing*, pages 1–13, 2023.
- [12] A. Inés, C. Domínguez, J. Heras, et al. Deepclas4bio: Connecting bio-imaging tools with deep learning frameworks for image classification. *Computers in Biology and Medicine*, 108:49–56, 2019.
- [13] Á. Casado-García, G. Chichón, C. Domínguez, et al. Motilityj: An open-source tool for the classification and segmentation of bacteria on motility images. *Computers in Biology and Medicine*, 136:104673, 2021.
- [14] Á. Casado-García, M. García-Domínguez, J. Heras, et al. Prediction of epiretinal membrane from retinal fundus images using deep learning. *Advances in Artificial Intelligence*, pages 3–13, 2021.